

**TPC#1****Data de entrega:** 9 de Março de 2023**Autores:** António Santos (100%); Diogo Reis (100%); Pedro Coelho (100%)

1. (a)

Ora, pretendemos provar que o método de Newton converge linearmente para  $x_*$ , ou seja, que a sucessão  $x_k$  converge linearmente para  $x_*$  se existir  $r \in (0,1)$  tal que:

$$\frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|} \leq r, \quad \forall k > k_0$$

.

Sabemos que o método de Newton nos é dado por:  $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$ .

Utilizando a expansão do Método de Taylor para um ponto na vizinhança de  $x_*$  vem:

$$f(x_n) = f(x_*) + f'(x_*)(x - x_*) + \frac{1}{2}f''(\eta)(x - x_*)^2$$

, tal que  $\eta = x_* + \theta x_n, \theta \in (0,1)$ .

Utilizando o facto de que  $f(x_*) = f'(x_*) = 0$  vem que:

$$f(x_n) = \frac{1}{2}f''(\eta)(x - x_*)^2$$

, tal que  $\eta = x_* + \theta x_n, \theta \in (0,1)$ .

Aplicando então o método de Newton no ponto  $x_*$ :

$$\begin{aligned} x_{n+1} - x_* &= x_n - x_* - \frac{f''(\eta)(x_n - x_*)^2}{2f'(x_n)} \Leftrightarrow \\ \Leftrightarrow x_{n+1} - x_* &= (x_n - x_*)\left(1 - \frac{f''(\eta)(x_n - x_*)}{2f'(x_n)}\right) \end{aligned}$$

Como  $f''(x_*) \neq 0$ , existe  $r$  tal que  $|1 - \frac{f''(\eta)(x_n - x_*)}{2f'(x_n)}| \leq r$ .

Assim,

$$\begin{aligned} |x_{n+1} - x_*| &= |x_n - x_*| \left|1 - \frac{f''(\eta)(x_n - x_*)}{2f'(x_n)}\right| \\ \Leftrightarrow |x_{n+1} - x_*| &\leq |x_n - x_*| r \end{aligned}$$

Como tal, prova-se que o método de Newton converge linearmente para  $x_*$ .

(b)

O método do ponto fixo é dado por:  $x_{n+1} = g(x_n)$

Podemos implementar o método do ponto fixo a partir do método de Newton da seguinte forma: Seja  $g(x_n) = x_n - \frac{f(x_n)}{f'(x_n)}$  e  $g(x_*) = x_*$ .

Desenvolvendo a série de Taylor de  $g(x_n)$  em torno de  $x_*$  vem:

$$g(x_k) = g(x_*) + g'(x_*)(x_n - x_*) + \frac{1}{2}g''(x_*)(x_n - x_*) + \frac{1}{6}g'''(\eta)(x_n - x_*)^3$$

, tal que  $\eta = x_* + \theta x_n, \theta \in (0,1)$

Ora,

$$g'(x_*) = 1 - \frac{(f'(x_*))^2 - (f''(x_*))f(x_*)}{(f'(x_*)^2)}$$

$$g''(x_*) = \frac{-2f(x_*)(f''(x_*))^2 - f(x_*)f'(x_*)f'''(x_*) - (f'(x_*))^2 f''(x_*)}{(f'(x_*))^3}$$

$$g'''(x_*) = \frac{-(f'(x_*))^3 f'''(x_*) - (f'(x_*))^3 (f'''(x_*)) + 3(f'(x_*))^2 (f''(x_*))^2 - f(x_*)(f'(x_*))^2 f'''(x_*) + 6f(x_*)f'(x_*)f''(x_*)f'''(x_*) - 6f(x_*)(f''(x_*))^3}{(f'(x_*)^4}$$

Utilizando o facto de que  $f(x_*) = f''(x_*) = 0$  podemos simplificar as derivadas  $g(x_*)$ .

Vem então que:

$$g'(x_*) = g''(x_*) = 0 \text{ e } g'''(x_*) \neq 0$$

Como tal, e, aplicando as propriedades das normas, vem que:

$$x_{n+1} = g(x_*) + \frac{1}{6}g'''(\eta)(x_n - x_*)^3 \Leftrightarrow$$

, tal que  $\eta = x_* + \theta x_n, \theta \in (0, 1)$

$$\Leftrightarrow x_{n+1} - x_* = \frac{1}{6}g'''(\eta)(x_k - x_*)^3 \Leftrightarrow$$

, tal que  $\eta = x_* + \theta x_n, \theta \in (0, 1)$

$$\|x_{k+1} - x_*\| \leq \|x_k - x_*\|^3 \left\| \frac{1}{6}g'''(\eta) \right\|$$

Portanto, atendendo ao facto de que  $\left\| \frac{1}{6}g'''(\eta) \right\| > 0$  mostramos que quando  $f(x_*) = 0$ ,  $f''(x_*) = 0$  e  $f'(x_*) \neq 0$  e  $f'''(x_*) \neq 0$  o método de Newton converge cubicamente para  $x_*$ .

2. Vamos, inicialmente, obter uma relação entre os erros absolutos entre  $\|x_1 - x_*\|$  e  $\|x_0 - x_*\|$  com  $F(x_*) = 0$ , assumindo  $J(x_0)$  invertível (o que provamos de seguida) e  $\|e_0\| \leq c\|F(x_0)\|^2$ .

Pela fórmula recursiva do método de Newton vem:

$$x_1 - x_* = x_0 - x_* - J(x_0)^{-1}(F(x_0) + e_0) \Leftrightarrow$$

$$\Leftrightarrow x_1 - x_* = J(x_0)^{-1}J(x_0)(x_0 - x_*) - J(x_0)^{-1}(F(x_0) + e_0 - F(x_*)) \Leftrightarrow$$

$$\Leftrightarrow x_1 - x_* = J(x_0)^{-1}[F(x_*) - F(x_0) + e_0 + J(x_0)(x_0 - x_*)] \Leftrightarrow$$

,  $F(x_*) = 0$

$$\Leftrightarrow \|x_1 - x_*\| \leq \|J(x_0)^{-1}\|[\|e_0\| + \|-F(x_0) + J(x_0)(x_0 - x_*)\|] \Leftrightarrow$$

,  $\|e_0\| \leq c\|F(x_0)\|^2$

$$\Leftrightarrow \|x_1 - x_*\| \leq \|J(x_0)^{-1}\|[c\|F(x_0)\|^2 + \|-F(x_0) + J(x_0)(x_0 - x_*)\|] \Leftrightarrow$$

,

$$\Leftrightarrow \|x_1 - x_*\| \leq \|J(x_0)^{-1}\|[c\|F(x_0) - F(x_*)\|^2 + \frac{\gamma}{2}\|(x_0 - x_*)\|^2] \Leftrightarrow$$

,  $c\|F(x_0) - F(x_*)\|^2 \leq cl^2\|x_0 - x_*\|^2$  pois é continua à Lipschitz.

$$\Leftrightarrow \|x_1 - x_*\| \leq \|J(x_0)^{-1}\|(cl^2 + \frac{\gamma}{2})\|(x_0 - x_*)\|^2$$

Vamos agora analisar o caso geral:

Começemos por colocar uma bola centrada em  $x_*$  dentro de  $D$ , o que é possível pois  $D$  é aberto. Seja  $r > 0$  o raio da bola. Vamos considerar  $\epsilon \leq r$  tal que  $\|x_0 - x_*\| \leq \epsilon$ , ou seja:  $x_0$  está na bola, e, consequentemente em  $D$ .

Provamos inicialmente que se  $J(x_0)$  for invertível:

$$\|x_1 - x_*\| \leq \|J(x_0)^{-1}\|(cl^2 + \frac{\gamma}{2})\|(x_0 - x_*)\|^2$$

.

Temos agora de garantir que  $J(x_0)$  é invertível, uma vez que pelas condições do teorema 1  $J(x_*)$  é não singular e  $\|(J(x_*))^{-1}\| \leq \beta$ .

Seja  $J(x_0)$  tal que  $\|[J(x_*)]^{-1}(J(x_*) - J(x_0))\| \leq 1$

Então  $J(x_0)$  invertível e:

$$\|[J(x_0)]^{-1}\| \leq \frac{\|[J(x_*)]^{-1}\|}{1 - \|[J(x_*)]^{-1}(J(x_*) - J(x_0))\|}$$

Ora,

$$\|[J(x_*)]^{-1}(J(x_*) - J(x_0))\| \leq \|J(x_*)^{-1}\|\|(J(x_*) - J(x_0))\| \leq \beta\gamma\|x_* - x_0\| \leq \frac{1}{2} < 1$$

,

$$\|x_* - x_0\| = \epsilon \text{ e } \epsilon \leq \frac{1}{2\beta\gamma}$$

Assim,

$$\frac{\|[J(x_*)]^{-1}\|}{1 - \|[J(x_*)]^{-1}(J(x_*) - J(x_0))\|} \leq \frac{\beta}{1 - \frac{1}{2}} = 2\beta$$

Raciocionando indutivamente estabelece-se que para todo o  $k$  tal que  $J(x_k)$  é não singular que

$$\|x_{k+1} - x_*\| \leq 2\beta(cl^2 + \frac{\gamma}{2})\|x_k - x_*\|^2$$

.

o que, tomando  $M = 2\beta(cl^2 + \frac{\gamma}{2})$  equivale a:

$$\|x_{k+1} - x_*\|M \leq \|x_k - x_*\|^2$$

.

e portanto, pelas condições do Teorema 1, mostra-se que a sucessão  $x_k$  converge quadraticamente para  $x_*$ .

3. O método de Newton é uma das principais formas para calcular valores e vectores próprios de uma matriz através de métodos iterativos. Para tal, é necessária uma aproximação inicial do vector próprio correspondente ao maior valor próprio da matriz.

Para esta aproximação deve ser escolhido um vector unitário, pois assim garantimos que em cada iteração o vector resultante também será unitário, além disso, o vector deve ser arbitrário normalizado fazendo com que o método comece a convergir a partir de qualquer ponto no espaço vectorial em que a matriz actua.

Quando se aplica o método de Newton a uma matriz  $A$  com um vector próprio unitário, o vector que obtemos é uma aproximação do maior vector próprio da mesma.

Posto isto, devemos ter em atenção a escolha do vector inicial a fim de obtermos uma convergência rápida e estável.

Para a o programa pretendido começámos por definir uma matriz com quadrada com 4 elementos inteiros a variar entre 0 e 10, uma matriz identidade de igual ordem e um vector com o mesmo número de elementos. Normalizámos o vector anterior e calculámos uma aproximação para o valor próprio, tal como sugerido no enunciado.

```
clc; close all; clear;

n = 4; % Ordem da matriz
A = randi([0 10],n); % Matriz arbitrária de ordem n com elemntos a variar entre 0 e 10
I = eye(n); % Matriz identidade de ordem n
x = rand(n, 1); % Vector arbitrário
x = x / norm(x); % Normalização do vector arbitrário anterior, sendo norm(x) a norma do vector
y = x'*A*x; % Valor próprio de A
tol = 1e-10; % Tolerância
kmax = 100; % #máximo de itações
k = 0; % Iteração inicial
erro = tol + 1; % Iniciar o ciclo
aux = 1; % Variável auxiliar para o cálculo do vetor próprio
```

Seguidamente implementámos um ciclo *while* com o método de Newton. O ciclo começa por resolver o sistema linear que nos é dado no enunciado  $J_F(x_k, \lambda_k)p_k = -F(x_k, \lambda_k)$ , a

variável  $b$  representa a matriz  $\begin{bmatrix} x_{k+1} \\ \lambda_{k+1} \end{bmatrix}$  apresentada no enunciado.

```
fprintf(' \n Matriz A: \n');
disp(A);

disp('-----');
disp(' Iteração      Valor próprio ');
disp('-----');
fprintf('      %2.0f      %20.16f \n',k,y);

% Ciclo de Newton
while (erro > tol) && (k < kmax)
    F = Funcao(A,x,y);
    J = Jacobiana(A,x,y,I);
    pk = - J \ F;
    v = [x ; y]; % Vector normalizado anteriormente com y na ultima linha
    b = v + pk; % Soma do vector v com o vector pk, ficando b com n+1 elems
    x = b(1:n); % x toma os valores do n primeiro elementos de b
    y = b(n+1); % y toma o último valor de b
    erro = norm(F);
    k = k + 1;
    fprintf('      %2.0f      %20.16f \n',k,y); % print do valor próprio na iteração k
end
```

Fizemos um novo ciclo para a impressão do vector próprio. No final estão definidas as funções dadas no enunciado  $F(x, \lambda)$  e  $J_F(x, \lambda)$ .

Seguidamente ficam dois testes feitos com matrizes escolhidas aleatoriamente.

```

fprintf(' \n Vector próprio: \n');

    % Impressão do vector próprio
while (aux<n+1)
    fprintf(' %20.16f \n',x(aux));
    aux=aux+1;
end

fprintf(' \n Matriz A: \n');
disp(A);

function F = Funcao(A, x, y) % Funcao F conforme o enunciado
F = [A*x - y*x; x'*x - 1];
end

function J = Jacobiana(A, x, y, I) % Jacobiana conforme o enunciado
J = [A - y*I, -x; 2*x', 0];
end

```

Command Window

```

Matriz A:
     3     10      4      5
     9      3      6      8
     6      8      0     10
     6      8      0      1

-----
Iteração      Valor próprio
-----
 0    17.7071146259727463
 1    22.6467477879226919
 2    21.8854648613331122
 3    21.7535203626229396
 4    21.7498164484588763
 5    21.7498148824928670
 6    21.7498148824927249

Vector próprio:
0.5145704880856856
0.5714950333917288
0.5218750227636221
0.3691301941257513
fx >>

```

Command Window

```

Matriz A:
     1      1      7      2
     8      6      8     10
     3      2      4      1
     5      7      0      9

-----
Iteração      Valor próprio
-----
 0    15.6698891524314536
 1    19.1983368701525379
 2    18.6652069951966340
 3    18.6085600953214261
 4    18.6080608670862553
 5    18.6080608465419814
 6    18.6080608465419814

Vector próprio:
0.1852362314025996
0.7321835896286510
0.1814004008076112
0.6298322191195872
fx >>

```